

Mejora de la representatividad espacial de estimaciones de radiación solar de Bases de Datos Satelitales para Salta y Jujuy, usando herramientas de Inteligencia Artificial

Lic. Rubén D. Ledesma

Universidad Nacional de Salta

Director: Dr. Germán Salazar | Jurado: Dr. Rodrigo Alonso-Suárez, Dr. Raúl Righini, Dr. Javier Trenti

6 de Julio de 2026

Estructura de la presentación

1. Motivación y problema
2. Marco: Adaptación al Sitio + Aprendizaje Automático
3. Datos y zona de estudio (NOA)
4. Diagnóstico: modelos sin adaptar
5. Resultados: cuatro enfoques de adaptación
6. Generalización espacial
7. Conclusiones y perspectivas

Idea clave: Una hipótesis central — *integrar Aprendizaje Automático permite capturar relaciones no lineales entre la irradiancia modelada y variables locales, reduciendo el error de las estimaciones y extendiendo la corrección a celdas sin medición.*


Parte 1

Motivación y problema

El recurso solar es estratégico... y hay que medirlo bien

- En 2024 la generación fotovoltaica superó los **2.000 TWh** ($\approx 7\%$ de la electricidad mundial).
- Diseñar, financiar y operar plantas FV exige conocer el recurso solar (GHI) con precisión, en el espacio y en el tiempo.
- La GHI es además una variable transversal: clima, hidrología, agricultura, ambiente.

Idea clave: Sin una buena caracterización del recurso, todo lo que se construye encima (energía, financiamiento, clima) hereda el error.



Noroeste Argentino (NOA): alto potencial solar, baja densidad de medición.

El problema en dos planos: espacial y temporal

Medir en superficie es lo más fiable...

- Piranómetros homologados (ISO 9060:2018), dataloggers, calibración y mantenimiento.
- Caro y logísticamente difícil de sostener.

...pero es escaso e intermitente

- *Problema espacial*: no se puede medir en todos los sitios necesarios.
- *Problema temporal*: registros con *gaps*, series cortas.

Contexto argentino

- **Sin estaciones BSRN** en el país.
- Proyecto ENARSOL (2012, 40 estaciones) discontinuado.
- El NOA: alto potencial, muy baja densidad radiométrica y sin trazabilidad sistemática.

La alternativa: satélite y reanálisis — cobertura, pero con error

Resuelven la cobertura

- Satélite (desde 1997) y reanálisis (desde 1940): regiones enteras, series largas y continuas.

Pero son estimaciones de un modelo

- No son mediciones: arrastran sesgos sistemáticos y errores.
- El error se agrava en **topografía compleja** (Salta y Jujuy): nubosidad y efectos orográficos mal representados.

Por qué importa el error

Sobreestimar la GHI un 10% sobreestima la energía generada (MWh/año) y los ingresos $\Rightarrow$ riesgo en la bancabilidad de un proyecto FV.

En generación domiciliaria, esperar 5,5 y obtener 4,8 kWh/m²/día desalienta al usuario.

Idea clave: El error de la estimación se *propaga* a todo lo que la usa como entrada.

Pregunta, hipótesis y objetivo

Pregunta

¿Cómo corregir las estimaciones satelitales/reanálisis usando las pocas mediciones disponibles, y *propagar* esa corrección a zonas sin medición en Salta y Jujuy?

Hipótesis

El aprendizaje automático permite capturar relaciones **no lineales** entre la irradiancia modelada y las variables locales, reduciendo errores y sesgos sistemáticos de las bases satelitales.

Objetivo

Desarrollar, adaptar y evaluar modelos que mejoren la precisión y la representatividad espacial de la GHI en el NOA, y proponer estrategias para extender las correcciones a celdas sin medición directa.

Parte 2

Adaptación al Sitio y Aprendizaje Automático

¿Qué es la Adaptación al Sitio (SA)?

Definición operativa. Conjunto de métodos estadísticos que corrigen errores sistemáticos y aleatorios de las estimaciones modeladas, usando **mediciones de superficie** de un período corto como referencia.

Analogía del termómetro

Un agricultor escucha el pronóstico (la *estimación*). Instala un termómetro y mide un tiempo (la *medición local*). Descubre un sesgo fijo (-5°C en invierno, $+3^{\circ}\text{C}$ en verano) y lo corrige. Aun cuando retira el sensor, las estimaciones corregidas representan mejor su finca. **Eso es SA.**

Idea clave: Un período breve de medición de calidad alcanza para corregir series largas — bajo el supuesto de que la relación se mantiene estable.


Proceso conceptual: ajustar en el solapamiento, aplicar a toda la serie

Dos pasos

1. **Ajuste:** en el período de *overlap* (medición $\cap$ estimación) se entrena la función de corrección.
2. **Aplicación:** la función se extiende a toda la serie modelada.

En su forma más simple:

$$\text{GHI}_{\text{adaptada}} = f(\text{GHI}_{\text{modelada}})$$



Antes (rojo): sesgo bajo la línea 1:1. Después (verde): alineado a 1:1.

Estado del arte: de lo estadístico a lo no lineal

Cinco familias de SA (Polo et al., 2016 — IEA Task 46): físicos · estadísticos · híbridos · post-proceso · combinados.

El giro hacia Machine Learning

- **Babar (2020)**: Random Forest sobre CLARA-A2/ERA5; corrige el sesgo y reduce el RMSE — de los primeros en usar ML para la función de ajuste.
- **Narváez (2021)**: RF $\approx$ 38% mejor que QM/MLR en series horarias.
- **Salamalikis (2022)**: modela $\Delta_{\text{GHI}} = \text{GHI}_{\text{med}} - \text{GHI}_{\text{mod}}$ (desestacionaliza); sesgo -50%.
- **Zainali (2024)**: ML supera a lo estadístico, pero el resultado depende del régimen climático.

Idea clave: La literatura ya advierte: *no existe un modelo universalmente superior*; el resultado depende del sitio.

Características, ventajas y límites de la SA

Ventajas

- Reducción significativa del sesgo.
- Mejora consistente de las métricas.
- Flexibilidad: de modelos simples a ML.

Características

- ~ 1 año de overlap suele bastar para entrenar.
- Aplicable a satélite y reanálisis, en varias escalas.

Límites

- Requiere datos locales de alta calidad.
- Alcance esencialmente **local**.
- No todos los métodos generalizan entre regiones.
- **Estacionariedad temporal**: el ajuste se calibra en un overlap corto y se extrapola a décadas — supone que la relación no deriva (degradación de sensores, cambio de plataforma, deriva de aerosoles).

Idea clave: El supuesto de estacionariedad es el flanco honesto del método y reaparece al final de esta defensa.

Modelos de regresión empleados

Lineales

- **SLR**: un regresor (GHI_{mod}).
- **MLR**: varios regresores; interpretable, barato.

No lineales

- **MLP** (perceptrón multicapa): aproximador universal; riesgo de sobreajuste.
- **Random Forest / XGBoost**: ensambles de árboles; capturan no linealidades e interacciones.

Idea clave: En SA, GHI_{mod} *debe* estar entre los regresores: si no, deja de ser adaptación y pasa a ser estimación.

Entrenamiento, validación, prueba y métricas

Partición (siguiendo Polo 2016/2020, ≥ 1 año de calibración)

- Entrenamiento / validación / prueba independientes.
- Control del sobreajuste y búsqueda de hiperparámetros.

x: medido, y: estimado. **MBE**=sesgo; **MAE/RMSE**=dispersión (RMSE penaliza outliers).

Métricas (relativas, % de la media medida)

$$\text{MBE} = \frac{1}{n} \sum (y_i - x_i)$$

$$\text{MAE} = \frac{1}{n} \sum |y_i - x_i|$$


$$\text{RMSE} = \sqrt{\frac{1}{n} \sum (y_i - x_i)^2}$$

Idea clave: Todo se reporta en % relativo a la media de GHI de cada sitio: hace comparables valle y altiplano.

Parte 3

Datos y zona de estudio

Cinco estaciones del NOA



ID	Sitio	Período	Alt. (m)	Clima
Yu	Yuto	2017–2018	401	Cwa
Sa	Salta	2009–2020	1233	Cwb
Sca	San Carlos	2012–2013	1624	Cwb
Ero	El Rosal	2016–2018	3355	BSk
Lq	La Quiaca	2018–2023	3500	BSk

- Amplio rango altitudinal y climático.
- GHI a 1 minuto (promedio de 6 muestras a 10 s).
- Köppen–Geiger; piranómetros ISO 9060:2018 clase A/B.

Heterogeneidad instrumental: un piso de error desigual

Sitio	Instrumento	Clase ISO
Sa	Eppley PSP	A (patrón secundario)
Lq	Kipp & Zonen CMP11	
Yu	Kipp & Zonen CMP11	
Sca	Kipp & Zonen CMP3	inferior
Ero	Kipp & Zonen CMP3	inferior

- Incertidumbre instrumental intrínseca: calibración y deriva, respuesta coseno, dependencia térmica, *thermal offset*.
- Calibración periódica en **GERSolar (UNLu)** $\Rightarrow$ acota la componente de calibración y aporta trazabilidad.

Implicancia metodológica

La GHI medida es la **referencia** del MBE/MAE/RMSE: su error propio se propaga y fija un **piso**. Mejoras de magnitud comparable a la incertidumbre de medición *no* son, por sí solas, evidencia concluyente.

Idea clave: Sca y Ero (CMP3) tienen un piso de error mayor: lo tengo en cuenta al comparar sitios.

Control de calidad de las mediciones

Procedimiento basado en Nollas (2023), con inspección visual previa. Sólo GHI $\Rightarrow$ versión reducida.

- **F1–F2:** límites físicos (función de E , S , θ_z).
- **F3:** descarta $k_t > 1,4$ con $\text{Sol} < 10^\circ$ sobre el horizonte.

Datos diurnos retenidos

Sitio	% retenido
Yu	73%
Sa	82%
Sca	72%
Ero	$\approx 84\%$
Lq	69%

Idea clave: Sin QC, los datos anómalos contaminarían la referencia y, por lo tanto, toda la adaptación.

Productos evaluados


Producto	Tipo	Base	Resolución
CAMS (Heliosat-4)	satelital (físico)	MSG	~16 km, 15 min
LSA-SAF (MDSSFTD)	satelital (híbrido)	MSG	~16 km, 15 min
ERA5	reanálisis	ECMWF	~31 km, horaria
MERRA-2	reanálisis	NASA GEOS-5	~50 km, horaria

- CAMS y LSA-SAF comparten información satelital de base (MSG).
- ERA5 aporta además covariables meteorológicas (temperatura, viento, vapor de agua) sobre grilla regular — clave para la generalización (más adelante).
- PSM/NSRDB se omitió por cobertura temporal limitada.



Desempeño a 15 minutos: no hay un ganador único

- **LSA-SAF**: tiende a sobreestimar ($MBE > 0$).
- **CAMS**: más balanceado, pero subestima en Ero y Lq.
- El mejor producto **depende del sitio**:
LSA-SAF gana en Ero/Lq; CAMS en Yu/Sa.



MBE/MAE/RMSE relativos a 15 min.

Idea clave: No conviene confiar en un único producto satelital: hay que evaluar localmente.


¿De qué depende el error? Nubosidad y geometría solar

Índice de claridad k_t y variabilidad

- El rRMSE crece cuando k_t baja (cielo cubierto/parcial): la radiación difusa domina y el modelo falla.
- Crece también con la variabilidad de ΔGHI ($\geq 150\text{--}200\text{ W/m}^2$).

Ángulo cenital (SZA)

- Forma de "U": mínimo en $30^\circ\text{--}50^\circ$, peor en $> 70^\circ$.




rRMSE vs SZA (CAMS continua, LSA-SAF punteada).

Estacionalidad del error


- El rRMSE **aumenta en verano** en casi todos los sitios: más nubosidad convectiva.
- **Yuto** es la excepción: error estable todo el año.
- Señal de que la nubosidad estacional afecta de forma diferenciada a cada sitio.

Idea clave: Hay estructura estacional en el error
⇒ motiva el enfoque de desestacionalización (Enfoque 4).



Escala horaria y una anomalía instructiva: CAMS en El Rosal

- A escala horaria, en cielo despejado satélite $\approx$ reanálisis; con nubosidad variable, el reanálisis empeora.
- **CAMS en Ero:** error y sesgo anómalos — **sobreestima la nubosidad.**
- Causa documentada por los desarrolladores: un píxel desértico (frío en térmico, brillante en visible) genera *falsos positivos de nube* en APOLLO/SEV.




GHI medida vs CAMS/LSA-SAF, dos días en Ero.

Idea clave: Un modelo globalmente robusto puede fallar localmente: argumento directo a favor de la adaptación al sitio.

Resolución espacial $\neq$ más error

- Celdas: LSA-SAF $\sim 0.05^\circ$ · ERA5 0.25° · MERRA-2 $0.5^\circ \times 0.625^\circ$.
- Mayor resolución capta mejor la variabilidad de pequeña escala.
- **Pero** una celda más gruesa promedia en el espacio y en el tiempo (paso de estructuras nubosas): con muestreo poco frecuente, ese promediado puede ser *deseable*.

Idea clave: Menor resolución no implica mayor error: el promediado integra el campo de irradiancia de forma más estable.



Síntesis del diagnóstico


- Satélite > reanálisis *en general*, pero el error crece en alta montaña y con nubes de desarrollo vertical.
- El error a 15 min supera al horario: capturar procesos transitorios es difícil.
- Casos atípicos locales (CAMS/Ero) muestran que la fiabilidad **no es uniforme**.

Conclusión del diagnóstico

Los productos disponibles son un insumo valioso para regiones con poca medición, pero **insuficientes para alta precisión en el NOA sin ajuste local**. Esto justifica el desarrollo metodológico que sigue.



Cuatro enfoques, una pregunta de fondo




La pregunta que atraviesa el capítulo

¿La mejora viene de la **complejidad del algoritmo** o de la **estructura de la información** que le damos?

Enfoque 1 — Adaptación con una sola variable

$$GHI_{adaptada} = f(GHI_{modelada})$$

- Corrige el sesgo global; mejora en **todos** los sitios, pero de forma acotada.
- Ejemplo Ero (15 min): RMSE de **40.9%** (CAMS) y **26.5%** (LSA-SAF) baja a $\sim 31\%$ y $\sim 25\%$.
- La mejora es mayor donde el modelo crudo era peor (más margen).




Ero: los adaptados se acercan a la línea 1:1.

Enfoque 1 — Hallazgo clave: $SLR \approx MLP \approx XGB$

- Con **un único regresor**, lineales y no lineales rinden casi igual.
- La calidad del dato de entrada impone un **techo** a lo que un modelo sofisticado puede ganar.
- El MLP puede *sobreajustar* con un solo regresor (menos consistente entre métricas).

Idea clave: Aumentar la complejidad del algoritmo, por sí solo, no compra precisión.



CAMS, 15 min: crudo vs adaptado (datos de la tesis).

Enfoque 2 — Múltiples regresores: primero, análisis exploratorio

Se parte de un conjunto amplio de variables astronómicas, atmosféricas y meteorológicas (N, SZA, α , TOA, GHI_{largo2}, δ , Fn, E0, mr, tm, viento, vapor de agua, punto de rocío) y se **selecciona** por relevancia física y estadística.

Correlación de Pearson/Spearman con la GHI medida

- **GHI_{largo2}** (cielo claro): 0.71–0.87 — la más informativa.
- **tm** (temperatura media ERA5): 0.41–0.55 — moderada y coherente.
- Humedad (tcwv, d2m): correlación muy baja $\Rightarrow$ se descartan.

Idea clave: Seleccionar variables relevantes pesa más que sumar regresores: reduce multicolinealidad y sobreajuste.

Enfoque 2 — Lo que el filtro de correlación sí y no captura

Redundancia exacta: SZA y α

- $\alpha = 90^\circ$ – SZA: información idéntica.
- Correlación lineal perfecta $\Rightarrow$ el filtro de Pearson **la detecta y elimina una** antes de entrenar.

Redundancia oculta: N y δ

- δ es función determinística de N, pero **periódica y no monótona**.
- Pearson y Spearman quedan bajos $\Rightarrow$ el filtro **no** la captura; ambas se conservan.
- Inocuo: N y δ tienen correlación débil con la GHI $\Rightarrow$ contribución marginal.


Idea clave: Es una decisión consciente, no un error: el filtro lineal resuelve la colinealidad lineal, no la dependencia no lineal. Mejora menor a futuro: RFE/LASSO o selección sensible a no linealidades.

Enfoque 2 — Resultado: GHlargp2 + tm, gran salto

Con sólo GHI_{mod} , GHlargp2 y tm (horaria), el error cae fuerte y de forma **consistente entre sitios**:

- Ero (CAMS): RMSE $\rightarrow$ **19.6%**.
- Lq (CAMS): RMSE $\rightarrow$ **16.0%**.
- Desaparecen los empeoramientos puntuales del conjunto completo.

Idea clave: Selección física $\Rightarrow$ mejor ajuste y mejor generalización.




Crudo vs adaptado (MLR/MLP/XGB) con regresores seleccionados.

Enfoque 3 — Celdas satelitales adyacentes


- La irradiancia de un sitio forma parte de un campo **espacialmente coherente** (sistemas nubosos de mesoescala, decenas de km).
- Se incorporan como regresores las celdas vecinas (vecindad de von Neumann, **DM=1**: cuatro celdas cardinales).
- Rompe el paradigma clásico de **una sola celda**.

Idea clave: Aporta contexto espacial que un modelo de celda única no puede ver.



Enfoque 3 — Resultado: el contexto espacial manda, no el algoritmo

- Reducciones de RMSE del orden de **5–15%** según sitio y producto.
- Mayor mejora en entornos de alta variabilidad topográfica/atmosférica.
- **MLR estable** frente a MLP/XGB: la ganancia viene de la *información*, no de la complejidad.
- Sumar temperatura (caso TM2) refuerza la corrección.
- Robusto a 15 min y horario.



rRMSE con el enfoque de celdas adyacentes.

Enfoque 4 — Desestacionalización

Tres formulaciones sobre regresión lineal:

- **E1** directo: $GHI_{ad} = a GHI_{mod} + b$.
- **E2** (Salamalikis): modela el error $\Delta_{GHI} = GHI_{med} - GHI_{mod}$.
- **E3** desestacionaliza con cielo claro (ARGP-V2): $X = GHI_{mod} - GHI_{cc}$, $Y = GHI_{med} - GHI_{cc}$.


Resultado conceptual

E1 y E2 son **matemáticamente equivalentes** bajo regresión lineal. E3 aísla la componente determinística (geometría solar) y deja que la regresión aprenda sólo la **variabilidad atmosférica residual**: más estable y **interpretable** (a , b con sentido físico).

Idea clave: Especialmente valioso donde la estructura estacional es fuerte (Ero, Lq).

Síntesis comparativa — la conclusión matizada

LSA-SAF horario, dos extremos: **Sa** (valle, peor caso) y **Ero** (altiplano, mejor caso).



- **El sesgo siempre se corrige:** en Sa, MBE 17.9% → ~4%; en Ero, -7.7% → ~+1%.
- Dentro de un enfoque, **el regresor casi no cambia el resultado.**
- En **Ero** (cielo claro, fuerte estacionalidad), E2/E3/E4 convergen y mejoran mucho sobre E1.
- En **Sa** (valle convectivo) hay un **piso estructural** (~30–32%): ni el espacio ni la desestacionalización lo superan.

El mensaje central de los resultados

Estructura de la información > complejidad del algoritmo

El factor determinante de la mejora es **qué información se incorpora** —variables físicamente relevantes, contexto espacial, remoción de estacionalidad— y no el algoritmo de regresión. Un MLR bien alimentado iguala a MLP/XGB con menor costo y mayor interpretabilidad.

Recomendación operativa matizada

- Error dominado por **sesgo + estacionalidad** (altura, cielo claro) $\Rightarrow$ E2/E3/E4 son intercambiables; elegir por costo/interpretabilidad.
- Error dominado por **procesos locales de alta frecuencia** (valle convectivo) $\Rightarrow$ la SA quita el sesgo pero choca con un piso; la mejora futura depende de *productos de mayor resolución*, no de más adaptación.




El problema que queda: la corrección es local

- Cada modelo se ajusta donde *hay* medición. ¿Cómo llevarlo a celdas sin medición?
- Primero hay que saber **cuán lejos** puede viajar un modelo ajustado.

Idea clave: Sin una regla de transferencia, la SA se queda en los pocos puntos instrumentados — justo lo que se quería superar.

Validación cruzada entre sitios: transferencia direccional

- Entrenar en un sitio, probar en otro (modelo ERA5, MLR).
- El error crece cuando difieren las condiciones ambientales.
- Modelos de **alta montaña** transfieren bien a otra alta montaña; de baja altitud, a baja altitud.
- Transferencia **asimétrica**: $A \rightarrow B$ no implica $B \rightarrow A$.
- La **altitud** emerge como variable de control (estructura térmica, humedad).




Δ RMSE: filas=entrenamiento, columnas=prueba.

Propuesta: asignación por distancia 3D (lat, lon, altitud)

A cada celda sin medición se le asigna el modelo de la estación **más cercana en 3D**:

$$D_i = \sqrt{(x' - x'_i)^2 + (y' - y'_i)^2 + (z' - z'_i)^2}$$

- Coordenadas normalizadas (z-score) para que la altitud pese igual que lat/lon.
- Búsqueda eficiente con **KD-Tree**.
- Garantiza continuidad espacial del campo corregido, escalable a todo el dominio.



El punto objetivo (verde) hereda el modelo de la estación más próxima.

Validación independiente: Abra Pampa y Cerrillos (ERA5)

Dos estaciones **no** usadas en el ajuste (ex-red ENARSOL, 2017). El criterio 3D asigna: Ap→modelo de Lq; Ce→modelo de Sa.

	Ap RMSE	Ce RMSE
ERA5 crudo	19.7%	38.1%
ERA5 ajustado	19.6%	36.5%

	Ap MBE	Ce MBE
ERA5 crudo	2.6%	13.4%
ERA5 ajustado	1.8%	7.8%

- **Cerrillos:** sesgo reducido **más del 40%**.
- **Abra Pampa:** casi sin cambio — ERA5 ya representa bien la alta montaña seca; aun así baja el MBE.
- Mejoras modestas pero **consistentes**, y un campo regional espacialmente coherente.

Idea clave: La transferencia por similitud geográfica-altitudinal funciona en sitios nunca vistos.

¿Por qué ERA5 para la generalización?

- La generalización exige, en *cada* celda sin medición, tanto la GHI como **todos los regresores** usados en la adaptación.
- ERA5 provee irradiancia y covariables meteorológicas sobre **una misma grilla global, regular y continua**.
- LSA-SAF es más preciso puntualmente, pero **no** ofrece el conjunto completo de regresores de forma auto-consistente en puntos arbitrarios.

Idea clave: El criterio de generalización es independiente del producto; extenderlo a productos satelitales es trabajo futuro.



Conclusiones (1/2)

Sobre los modelos crudos

Satélite > reanálisis en general, pero insuficientes para alta precisión en el NOA sin ajuste local; la fiabilidad no es uniforme (CAMS/Ero).

Sobre la adaptación con regresores

Mejora en todos los sitios. **MLR bien configurado** basta en la mayoría de los casos; MLP/XGB se justifican sólo con más regresores y no linealidades marcadas. El **contexto espacial** (celdas adyacentes) es uno de los mayores aportes.

Sobre generalización

Los modelos adaptados conservan desempeño si hay **similitud geográfica y altitudinal**; habilita mapas regionales más confiables que los puramente satelitales.

Conclusiones (2/2) — Aportes de la tesis

1. Diagnóstico detallado del desempeño de modelos de GHI actuales en el NOA (15 min y horario).
2. Metodología de **Adaptación al Sitio con múltiples regresores**, propuesta y validada.
3. Demostración del valor de la **información espacialmente coherente** (celdas adyacentes).
4. Confirmación de que la SA puede **generalizarse** para construir mapas regionales de mejor calidad.

Idea clave: Metodología reproducible, escalable y de bajo costo: una alternativa eficaz frente a expandir redes de medición costosas.

Artículos en revistas con arbitraje

- *Machine Learning for Site Adaptation of Satellite-Derived Solar Irradiance in NW Argentina*. Ledesma & Salazar. **J. of Computer Science & Technology**, 25(2), 2025.
- *Machine Learning Site Adaptation for Optimizing Heliosat-4 GHI using Adjacent Satellite Cells*. Ledesma, Salazar, López, Nollas. **ASME J. Solar Energy Eng.**, 2026.
- *Performance Evaluation of Solar Irradiance Models at 11 Sites in South America*. Ledesma & Salazar. **ASME J. Solar Energy Eng.** (aceptado).

Congreso con arbitraje

- *Site Adaptation for GHI in Argentina Using a Multilayer Perceptron*. Salazar, Gueymard, Ledesma, Vilela. **ISES Solar World Congress 2025**, Fortaleza.

- **Nuevas fuentes:** GOES-16/19 (mejor posicionamiento sobre el NOA).
- **Vecindad espacio-temporal:** añadir información diferenciada en el tiempo, no sólo vecinos simultáneos.
- **Producción FV real:** validar y ajustar desde la energía, no sólo radiométricamente.
- **Expandir la validación cruzada:** nuevas estaciones de alta montaña.
- **Herramientas operativas:** plataformas web / API para instituciones.
- **Selección automática** (RFE, LASSO, permutación) y desestacionalización avanzada (Fourier, STL, wavelets).



Diapositivas de respaldo

Material de apoyo para el turno de preguntas

Respaldo — ¿Un año de overlap es suficiente y hay riesgo de estacionariedad?

La tensión aparente

Sostengo que ~ 1 año de overlap basta para *entrenar*, y a la vez listo la no estacionariedad como limitación.
¿Contradicción?

Respuesta: son dos afirmaciones sobre planos distintos.

- **Suficiencia estadística** (entrenamiento): un año cubre el ciclo estacional completo $\Rightarrow$ alcanza para *estimar* a , b y capturar la relación.
- **Validez de la extrapolación** (aplicación): aplicar esa función a *décadas* supone que la relación no deriva. Eso depende de la **representatividad** del año elegido y de la estabilidad del producto, no de la cantidad de datos.

Idea clave: Un año basta para *ajustar*; la estacionariedad gobierna por cuánto tiempo ese ajuste sigue siendo válido. No compiten.

Respaldo — Incertidumbre instrumental y el piso de error

- Fuentes: calibración y su deriva, respuesta direccional/coseno, dependencia térmica, no linealidad, selectividad espectral, *thermal offset* (termopila).
- CMP11/PSP (clase A) vs CMP3 (clase inferior): **pisos de incertidumbre desiguales** entre sitios.
- La GHI medida es la referencia de las tres métricas $\Rightarrow$ su error se propaga y fija un mínimo.
- **Lectura honesta:** mejoras del orden de la incertidumbre de medición no son, por sí solas, prueba concluyente de mejora del modelo. Las conclusiones se apoyan en las diferencias que *superan* ese margen.
- Mitigación: calibración periódica trazable en GERSolar (UNLu).

Respaldo — ¿Por qué vecindad $DM=1$ y no $DM=2$?

- Se adoptó la vecindad de **von Neumann ($DM=1$)**: las cuatro celdas cardinales, no las ocho de Moore.
- **Decisión de diseño**, no omisión: prioriza coherencia espacial de primer orden con un número acotado de regresores (menos multicolinealidad y sobreajuste).
- En la síntesis comparativa, las celdas adyacentes ya igualan o superan a múltiples regresores en altura, sin necesidad de ampliar el vecindario.
- **Limitación reconocida**: $DM=2$ (o vecindades ponderadas por distancia) podría capturar estructuras nubosas mayores — línea de trabajo futura.

- k_t (índice de claridad): GHI / irradiancia teórica en el tope de la atmósfera sobre plano horizontal.
- **Índice de variabilidad**: desviación estándar de las diferencias consecutivas de GHI en una ventana ($N = 10$):

$$\text{VarIndex}(t) = \sqrt{\frac{1}{N-1} \sum_{i \in \mathcal{W}(t)} [(GHI_i - GHI_{i-1}) - \overline{\Delta GHI}]^2}$$

- **SZA** / α : ángulo cenital solar y altura solar, $\alpha = 90^\circ - \text{SZA}$.
- **GHIargp2**: GHI de cielo despejado (modelo ARGP-V2, Ledesma 2023a).
- **E0**: factor de corrección Tierra-Sol; **mr**: masa de aire relativa.

Respaldo — Medias de GHI por sitio (normalización de métricas)

Sitio	Yu	Sa	Sca	Ero	Lq
GHI media (W/m ²)	429.2	432.9	554.4	628.4	648.7

Todas las métricas relativas (%) de la tesis están normalizadas respecto a estos valores, lo que permite comparar de forma justa sitios de valle y de altiplano.